

2023——CCF BDCI——基于运营商大数据的栅格 时序图预测

赛题任务

基于中国联通大数据能力，以栅格聚合后的各类数据为节点，节点之间的人群往来为边构建图谱，预测目标栅格的活跃指数以及消费指数，具体定义如下：

活跃指数：综合反应该栅格内人群的出行、上网以及通话活跃情况；

消费指数：综合反应该栅格内线上、线下消费情况。

数据介绍

训练集：

节点数据:20230104-20230403 共九十天 F_1——F_35个匿名特征（F_23,F_27为全零数据），active_index,consume_index两列标签

边数据：两两节点之间的特征（F_1,F_2,日期）

测试集：


A榜测试集: 20230403-20230407

B榜测试集: 20230408-20230410

方案介绍

采用时空图卷积神经网络模型与时序卷积神经网络模型进行融合

时序卷积神经网络（CNN）



通过数据挖掘，针对活跃指数和消费指数构造不同的特征，并分别搭建两个轻量化的两层CNN网络+全连接层模型。

特征工程构造：移除23，27两列全零特征，对消费指数构造（日，月，是否节假日，是否工作日，每周的第几天，一阶差分，日波动率，周波动率，月波动率，172维特征），对活跃指数构造（一阶差分，滑动窗口统计特征（最大，最小，均值），日波动率，周波动率，月波动率，266维特征）

（消费指数受工作日、节假日影响大，活跃指数受时间连续性影响大）

针对两个指数分别用不同的训练策略进行训练


对活跃指数：设置训练轮数为85轮；学习率为4e-4；adam优化器；余弦退火热重启的策略动态调节学习率

对消费指数：设置训练轮数为38轮；学习率为1e-4；adam优化器；余弦退火热重启的策略动态调节学习率


时空图卷积神经网络

数据处理

观察数据发现，对于需要预测的四天的边集分布与训练集有较大出入，训练集平均每天的边集大小为 1w+条，而测试集平均每天边集为 2w+，深入观察后发现仅 30 天内未出现的边就占据了 1w+条，因此为了保证测试集与训练集的分布，我们对 30 天内未出现的边进行了清洗。该方法为图神经网络带了约百分点的收益。



数据构建时主要是以时间为划分，将训练集的 90 个时间戳构造为对应 90 个图数据，每个图有 1140 个节点，同时由于我们采用了时空图卷积网络，对于特征的依赖是相对低的，在原有的栅格数据基础上，只额外提取了月，日，星期，是否周末，4 个维度特征，每个节点共 39 维节点特征。每个图对应的目标变量则是当天 1140 个 id 的 y。在 90 个空间图构建好后，我们采用了时序赛题常用的数据分割方法，滑窗法。滑窗长度 24，表示每次使用 24 张图进行输入，因为时空图的原因，24 张图需要按顺序输入，以便模型学习时序特征，因此我们重新建立了一个大图，在大图中，以 24 张图，每张图作为一个节点，边的连接表示按时间顺序进行连接。



在建模阶段，我们选取的图空间卷积模型主要是 GAT和 GraphSAGE,将滑窗后的 24 张图送入网络中，提取空间特征，并且在每个模块后加入残差连接。然后使用 lstm 进行时间特征提取，最后经过多个线性层进行回归预测。

- **GAT**: 引入**注意力机制**，在邻居节点聚合时为每个邻居分配不同权重，权重通过可学习的打分函数（如 $\text{LeakyReLU}(a(\mathbf{w}_x \cdot \mathbf{i} \parallel \mathbf{w}_x \cdot \mathbf{j}))$ ）动态计算。这使得模型能够区分不同邻居的重要性，适用于**有向图**和异构关系场景。
- **GraphSAGE**: 采用**采样 + 聚合策略**，通过固定数量的邻居采样（如 mean、LSTM、pooling 聚合器）实现**mini-batch 训练**，支持**归纳学习 (inductive)**，可在未见过的节点上直接推理。

训练策略：

多尺度反向传播：因为本题是 X-Y 型时序回归赛题，与 Y-Y 时序预测不同在于我们需要提供当前时序的 X 以回归对应的 Y。所以在计算 loss 时往往使用最后一维与对应的结果计算 loss，进行反向传播，但我们发现这样的方式很容易过拟合，因此我们在计算 loss 时不止使用最后的结果，而是使用最后 n 个结果进行计算，同时我们在训练中对 n 进行调整，使得模型预测逐渐调整，带来更好的泛化能力。

移动平均后处理：MA（MovingAverage）是处理时序的经典方法，我们将这种方法放在了后处理当中，为了防止模型的预测过于激进，我们使用模型预测的前几时刻值与当前时刻值进行一些加权的处理作为最后的当前时刻值。

模型融合

我们在使用两套方案的模型进行加权融合时，通过使用多个比例对两个结果进行加权融合，获得多个结果。然后对于这些结果中的每个 id，计算与其他结果中同 id 的 rmse，将与其他 id 的 rmse 计算结果之和作为该结果该 id 的投票指数。选择在该 id 中投票指数最小的结果作为最终结果中的该 id 的值。使用上述的方法不必纠结哪种加权比例最优，最终结果中可以包含多种比例的结果，而且结果保证了与所有结果的最优相似，可以尽可能大的降低比例不同带来分数抖动，是较为稳妥的融合方式。